Ecosistema de Automatización IA Autónomo para Negocios

Matriz de Optimización de Costos

Análisis del criterio de selección de modelo (Claude Haiku vs. Claude Sonnet) usado en el workflow, con estimación de costo por ejecución y comparación contra alternativas de un solo modelo. Precios verificados en la documentación oficial de Anthropic (platform.claude.com) al 2 de octubre de 2026.

Precios oficiales por millón de tokens (MTok)

Modelo	Input (USD/MTok)	Output (USD/MTok)	Uso en el workflow
Claude Haiku 4.5	$1.00	$5.00	Extraer datos (nodo "Extraer datos con Claude Haiku")
Claude Sonnet 4.5	$3.00	$15.00	Redactar propuesta (nodo "Redactar propuesta con Claude Sonnet")

Sonnet es 3x más caro que Haiku en input y 3x más caro en output. Por eso el criterio de asignación de modelo por tarea (y no un único modelo para todo el flujo) es la principal palanca de optimización de costos de este sistema.

Criterio de asignación de modelo por tarea

Tarea	Modelo	Justificación
Extracción de datos del email (nombre, email, necesidad)	Claude Haiku 4.5	Tarea de extracción estructurada, de baja complejidad y bajo riesgo de ambigüedad. No requiere razonamiento profundo ni redacción persuasiva. Usar un modelo más caro acá no mejora el resultado, solo encarece el costo por ejecución.
Redacción de la propuesta comercial (selección de servicio vía RAG + texto persuasivo)	Claude Sonnet 4.5	Tarea de mayor complejidad: requiere interpretar la necesidad del cliente, elegir el servicio más adecuado del catálogo (razonamiento) y redactar un texto comercial natural y persuasivo. La calidad de este paso impacta directamente la conversión del negocio, justificando el costo mayor.

Estimación de costo por ejecución

Estimación basada en los volúmenes de tokens observados durante las pruebas documentadas del sistema (emails cortos de 1 a 3 párrafos, catálogo de servicios de pocas filas). Los valores son aproximados: el costo real varía según el largo del email del cliente y el tamaño del catálogo.

Paso	Modelo	Input aprox. (tokens)	Output aprox. (tokens)	Costo estimado
Extraer datos	Haiku 4.5	~500	~150	$0.0013
Redactar propuesta	Sonnet 4.5	~1.200	~500	$0.0111
Total por ejecución	—	~1.700	~650	$0.0123

Cálculo: Haiku → (500 × $1 + 150 × $5) / 1.000.000 = $0.00125. Sonnet → (1.200 × $3 + 500 × $15) / 1.000.000 = $0.0111. Total ≈ $0.0123 por propuesta generada (poco más de 1 centavo de dólar).

Comparación contra alternativas de un solo modelo

Estrategia	Costo estimado por ejecución	Diferencia vs. actual	Observación
Actual: Haiku (extracción) + Sonnet (redacción)	$0.0123	—	Balance costo/calidad por tarea
Todo con Sonnet 4.5	~$0.0148	+20% más caro	Sobrecosto en una tarea simple que no lo necesita
Todo con Haiku 4.5	~$0.0050	-60% más barato	Riesgo de propuestas menos persuasivas o con peor selección de servicio del catálogo
Todo con Opus 5	~$0.0248	+100% más caro	Costo injustificado para esta complejidad de tarea

Proyección a escala

Volumen mensual de consultas	Costo mensual estimado (estrategia actual)
50 propuestas/mes	~$0.62
200 propuestas/mes	~$2.47
1.000 propuestas/mes	~$12.35

El costo de inferencia de IA es marginal frente al valor del negocio (propuestas comerciales que pueden representar ventas de cientos de miles de pesos). La optimización de modelo por tarea no busca ahorrar montos grandes en términos absolutos, sino evitar gasto innecesario sin sacrificar calidad donde importa.

Otras palancas de optimización disponibles (no implementadas en esta entrega)

Palanca	Ahorro potencial	Por qué no se implementó
Prompt caching (catálogo de servicios)	Hasta 90% en el input repetido del catálogo	El catálogo es pequeño en esta prueba; el ahorro se vuelve relevante con catálogos grandes o alto volumen
Batch API	50% en ejecuciones no urgentes	El flujo requiere respuesta en near real-time (poll de 1 minuto), incompatible con el procesamiento diferido de Batch API

Fuente de precios: documentación oficial de Anthropic, platform.claude.com/docs/en/about-claude/pricing (consultado el 2 de octubre de 2026).